

# Fundamentos de Deep Learning

HE2: IA Aplicada

# Back to the basics...

¿Qué es una regresión lineal?

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

¿Qué ocurre si le aplicamos las siguientes funciones?

$$f(z) = \frac{1}{1 + e^{-z}}$$

Regresión Logística /Neurona

**¡Esto se llama función de activación!**

$$f(z) = \max(0, z)$$

Neurona

$$f(x) = x$$

Neurona

# Back to the basics...

¿Qué es una regresión lineal?


$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

¿Qué ocurre si le aplicamos las siguientes funciones?


$$f(z) = \frac{1}{1 + e^{-z}}$$

$$f(z) = \max(0, z)$$



$$f(x) = x$$



## Ejemplo




Es equivalente a




¡Esto ya es una red neuronal!

# Redes neuronales: Capas



# Redes neuronales: Capas (visualización simplificada)



Capa 1

Capa 2

Capa final  
¿Cuántas neuronas?

# Redes neuronales: Ejercicio

Una empresa inmobiliaria quiere automatizar la valoración de viviendas para reducir tiempos de tasación y costos operativos. El modelo debe predecir el precio de venta basándose en seis características objetivas: área en metros cuadrados, número de habitaciones, edad de la propiedad, distancia al centro de la ciudad, índice socioeconómico del barrio y tasa de criminalidad local. Esto permitirá ofertas de valoración instantánea a clientes y optimizará estrategias de inversión.

Complete la arquitectura de la red neuronal y diga cuántos parámetros tiene:

Input: ??

Capa oculta 1: 8 neuronas (ReLU)

Capa oculta 2: 5 neuronas (ReLU)

Capa oculta 3: 3 neuronas (ReLU)

Output: ??

# Back to the basics...

¿Cómo se entrena una regresión lineal?

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

**Función de pérdida:** 
$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Encontrando los parámetros  $\beta$  que minimizan el error.



$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

$$\hat{\beta} = \arg \min_{\beta} MSE$$

### En econometría

$$\hat{\beta}_{OLS} = (X^{\top} X)^{-1} X^{\top} y$$

### Métodos numéricos

Descenso del gradiente:

1. Inicializamos los pesos
2. Calculamos el gradiente
3. Actualizamos los pesos en la dirección negativa del gradiente

$$\hat{\beta}_{GD}$$

# Gradiente de una función

¿Qué es un gradiente?

- Qué tan rápido algo cambia cuando se mueve en distintas direcciones.
- El **gradiente de una función** es un vector que apunta en la dirección y la tasa del crecimiento más rápido de la función.

$$f(x) = x^2 \qquad \nabla f = \frac{\partial f}{\partial x} = 2x$$

$$f(x, y) = x^2 + y^2 \qquad \nabla f = \left( \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) = (2x, 2y)$$


# Gradiente de una función

$$f(x) = x^2$$

$$\nabla f = 2x$$

Para  $x=-1$ , cuanto es el gradiente?

Para  $x=1$ , cuanto es el gradiente?



# Descenso del Gradiente

$$f(x) = x^2$$

$$\nabla f = 2x$$


1. Iniciamos (aleatoriamente) en  $x = -1.5$

2. Actualicemos para descender con el gradiente:

$$x_{nuevo} = x_{anterior} - \nabla f(x_{anterior})$$

$$x_{nuevo} = 1.5$$

**Qué ocurre si lo vuelvo a actualizar?**



# Descenso del Gradiente

$$f(x) = x^2$$


$$\nabla f = 2x$$

1. Iniciamos (aleatoriamente) en  $x = -1.5$   
Y con un **learning rate** de 0.1
2. Actualicemos para descender con el gradiente:

$$x_{nuevo} = x_{anterior} - \eta \nabla f(x_{anterior})$$

$$x_{nuevo} = -1.2$$

**Qué ocurre si lo vuelvo a actualizar?**




# Descenso del Gradiente: Regresión Lineal y Tipos

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

$$\nabla MSE(\beta) = \left( \frac{\partial MSE}{\partial \beta_0}, \dots \right)$$

Datos de entrenamiento



**Batch Gradient Descent**



$$\beta_{nuevo} = \beta - \eta \frac{1}{N} \sum_{i=1}^N \nabla MSE_i(\beta)$$

**Mini-Batch Gradient Descent**



$$\beta_{nuevo} = \beta - \eta \frac{1}{M} \sum_{i=1}^M \nabla MSE_i(\beta)$$

**Stochastic Gradient Descent**



$$\beta_{nuevo} = \beta - \eta \nabla MSE_i(\beta)$$

Con  $i$  siendo una  
observación aleatoria

# Ejercicio en clase

Se quiere construir una regresión lineal simple para predecir la calificación real de un estudiante con base a las horas de estudio. Se tienen 10 observaciones:

| Horas de Estudio (x) | Calificación Real (y) |
|----------------------|-----------------------|
| 1                    | 65                    |
| 2                    | 72                    |
| 3                    | 78                    |
| 4                    | 85                    |
| 5                    | 89                    |
| 6                    | 94                    |
| 7                    | 98                    |
| 8                    | 105                   |
| 9                    | 108                   |
| 10                   | 115                   |

$$y = \beta_0 + \beta_1 x$$

1. Inicializar los pesos en 0 y seleccione un learning rate de 0.01
2. Realice 5 iteraciones de actualización con **Batch Gradient Descent**

¿Cuales son los pesos luego de las 5 iteraciones?