

Fundamentos de NLP

HE2: IA Aplicada




Introducción al procesamiento de lenguaje natural

- Procesamiento de lenguaje natural es el área de la IA que se encarga del entendimiento de lenguaje natural del ser humano (escrito y hablado) a través de un computador.
- El término “natural” designa una variedad lingüística o forma de lenguaje humano con fines comunicativos.



¿Qué es un lenguaje?

- Un lenguaje humano es un sistema convencional basado en el uso de signos /palabras según un complejo sistema de reglas.



A,B,C,D,E,F...
a,b,c,d,....


GATA
GAT + A
raíz género

La gata corre en el jardín

Regla: Sujeto + Verbo + Complemento




Procesamiento de lenguaje natural



¿Cómo podemos dotar a las computadoras con la capacidad de comprender el lenguaje natural del ser humano (escrito y hablado)?.


¿Para qué sirve el NLP?

- Asistentes virtuales y chatbots inteligentes
- Análisis de sentimiento en texto
- Resumen automático de documentos
- Traducción automática entre idiomas
- Motores de búsqueda
- Extracción de información estructurada
- Clasificación de texto
- Interfaces conversacionales



¿Por qué el entendimiento
del lenguaje es una tarea
compleja?

Ambigüedad



Correferencia



?

La **lámpara** no cabe por la **puerta** porque **esta** es muy angosta.

?

?

La **lámpara** no cabe por la **puerta** porque **esta** es muy alta.

?

Preprocesamiento de texto

Tokenización

- **Entrada:** “Los amigos de Pedro”
- **Salida:** Tokens (unidad mínima para procesamiento)

Los

Amigos

De

Pedro

- **Tokens:** es una instancia de secuencia de caracteres.
- Cada token es ahora un candidato para una entrada a la construcción de un **índice**, después de un procesamiento adicional.
- Pero, ¿cuáles se consideran tokens válidos?
- **Música Ligera**
 - Un token o dos tokens?

Stop words

- ***Con una lista de parada, se excluye del diccionario las palabras más comunes.***

Intuición:

- Tienen poco contenido semántico: la, a, y, de, como.
- Hay muchos de ellos en todas colección. No sirve como criterio diferenciador de documentos.

Pero la tendencia es no hacer esto:

- Existen buenas técnicas de compresión, lo que significa que el espacio necesario para incluir palabras vacías en un sistema es muy pequeño.
- Hacen parte de la sintaxis de una oración correcta son necesarias para frases como.
 - Rey de Dinamarca
 - Vuelos a Bogotá
- Los recientes embeddings contextuales requieren de esta información.

Normalización

- *Es posible que necesitemos "normalizar" las palabras en el texto indexado y de la consulta.*
- U.S.A y USA son el mismo.
- Hay muchos de ellos en toda colección. No sirve como criterio diferenciador de documentos.
- Acentos: p. ej., francés, español, currículum vs. curriculum.
- Incluso en idiomas que normalmente tienen acentos, es posible que los usuarios no los escriban.
- El resultado son términos: un **término** es un tipo de palabra (normalizado), que es una entrada en nuestro **diccionario** del sistema IR.
- La tokenización y la normalización pueden depender del idioma y, por lo tanto, están entrelazadas con la detección del idioma.

Lematización

- *Reducir las formas flexivas/variantes a la forma base*
- **pan**: panadero - panadería - panecillo
- **pescar**: pescado - pesquero - pescador— pescadería
- Es mas fácil en ingles?:
- **be**: am, are, is (verbal)
- **car**: car, cars, car's, cars' (nominal)
- La lematización implica hacer una reducción "adecuada".
 - Se requiere de diccionarios con la morfología de las palabras.

Stemming

- ***Son reglas de corte (básicamente) que se construyen para cada lenguaje***

- automatizar(s), automático, automatización todo reducido a automat.
- automate(s), automatic, automation todo reducido a automat.

- ***Stemming realmente sirve?***

Inglés: resultados mixtos. Ayuda en recall a algunas consultas, pero perjudica la precisión en otras.

- Definitivamente útil para español, alemán, finlandés,... ¡30 % de aumento de rendimiento para los finlandeses!

Vectorización

Texto como datos

- Para poder utilizar el texto asociado a los ítems debemos primero transformarlo en datos que puedan ser utilizado por modelos de machine learning.
- El primer paso entonces es representar este texto como vectores.
 - Cada documento se representa como una serie de n números, donde cada número representa una dimensión y n es el tamaño del vocabulario de todos los documentos juntos.
- Los dos vectorizadores más populares son CountVectorizer y TF-IDFVectorizer.

Frecuencia documental

- Es la forma más sencilla de vectorizar el texto.
- Primero procesamos nuestros documentos (tokenización, normalización y stop words)
- Luego, mapeamos la frecuencia de palabras para cada documentos en una matriz
- Tenemos los siguientes documentos:
 - A: El sol es una estrella.
 - B: Un buen viajante no tiene planes.
 - C: Juan tiene una mascota nueva

buen	estrella	Juan	mascota	nueva	planes	sol	viajante
0	1	0	0	0	0	1	0
1	0	0	0	0	1	0	1
0	0	1	1	1	0	0	0

Los términos raros son mas informativos

- Los términos raros son más informativos que los términos frecuentes.
 - Recuerden las palabras de parada.
- Considere un término en la consulta que es raro en la colección (por ejemplo, *electroencefalografía*).
- Es muy probable que un documento que contenga este término sea relevante para la consulta *electroencefalografía*.
- Queremos un peso alto para términos raros en la **colección** como *electroencefalografía*. Mayor poder **discriminatorio**.

Ponderación idf

- df_t es la frecuencia documental del termino t (número de documentos que contienen t).
 - df_t es una medida inversa del grado de “informatividad” de t
 - $df_t \leq N$
- Se define la **frecuencia inversa documental** del termino t como:

$$idf_t = \log_{10} \left(\frac{N}{df_t} \right)$$

- Se usa el logaritmo para amortiguar la división.

Ejemplo idf

Suponga $N = 1.000.000$

termino	df_t	idf_t
calpurnia	1	6
animal	100	4
sunday	1,000	3
fly	10,000	2
under	100,000	1
the	1,000,000	0

$$idf_t = \log_{10} \left(\frac{N}{df_t} \right)$$

TF-IDF

- Podemos pensar que no todas las palabras en un documento pesan lo mismo.

$$w_{t,d} = tf \cdot idf_{t,d} = \log(1 + tf_{t,d}) \times \log_{10} \left(\frac{N}{df_t} \right)$$

Donde:

- tf_{td} es la frecuencia palabra t en el documento d
- df_t es el numero de documentos que contienen la palabra t
- N es el numero de documentos

Los vectores *tf-idf* resultantes luego son normalizados por la norma euclidiana. Al hacer esta transformación tendremos que el peso de una palabra será mayor si aparece con más frecuencia o si está presente en menos documentos.

Ejercicio en clase

Crear la matriz TF-IDF para los siguientes documentos:

- El perro ladra en el parque
- El gato duerme en la casa
- El perro corre en la casa

Pasos:

- Crear el vocabulario
- Crear matriz TF
- Crear matriz IDF
- Crear matriz TF-IDF

Vocabulario y TF

Vocabulario (7 términos): casa, corre, duerme, gato, ladra, parque, perro

Termino	D1	D2	D3
casa	0	1	1
corre	0	0	1
duerme	0	1	0
gato	0	1	0
ladra	1	0	0
parque	1	0	0
perro	1	0	1

IDF

$$\text{idf}_t = \log_{10} \left(\frac{N}{\text{df}_t} \right)$$

Termino	df	IDF
casa	2	0.176
corre	1	0.477
duerme	1	0.477
gato	1	0.477
ladra	1	0.477
parque	1	0.477
perro	2	0.176

TF-IDF

$$tf.idf_{t,d} = \log(1 + tf_{t,d}) \times \log_{10} \left(\frac{N}{df_t} \right)$$

Usamos $\log(1 + tf)$ con log natural:

Si $tf=0$, entonces 0

Si $tf=1$, entonces $\log(2) = 0.693$

Entonces:

Para $df=1$: $0.693 * 0.477 = 0.331$

Para $df=2$: $0.693 * 0.176 = 0.122$

Termino	D1	D2	D3
casa	0	0.122	0.122
corre	0	0	0.331
duerme	0	0.331	0
gato	0	0.331	0
ladra	0.331	0	0
parque	0.331	0	0
perro	0.122	0	0.122

Documentos como vectores

Norma L_2 y producto punto

- Un vector puede ser normalizado dividiendo cada uno de sus componente por la norma.

$$\|\vec{x}\|_2 = \sqrt{\sum_i x_i^2}$$

- Dividir un vector por su norma L_2 lo convierte en un vector unitario (de longitud 1) (en la superficie de la hiperesfera unitaria).
- El producto punto de dos vectores por otro lado se define.


$$\vec{q} \cdot \vec{d} = \|\vec{q}\| \|\vec{d}\| \cos \theta$$

Distancia del coseno

La similitud de coseno es la métrica fundamental para medir qué tan "cercanas" semánticamente están dos oraciones en un espacio vectorial.

$$\cos(\vec{q}, \vec{d}) = \frac{\vec{q} \cdot \vec{d}}{\|\vec{q}\| \|\vec{d}\|} = \frac{\vec{q}}{\|\vec{q}\|} \cdot \frac{\vec{d}}{\|\vec{d}\|} = \frac{\sum_{i=1}^{|V|} q_i d_i}{\sqrt{\sum_{i=1}^{|V|} q_i^2} \sqrt{\sum_{i=1}^{|V|} d_i^2}}$$

- q_i es el peso del término i en la consulta
- d_i es el peso del término i en el documento
- La medida esté entre -1 y 1. Geométricamente esta medida es el coseno entre el ángulo de los dos vectores en el espacio.
- Cuando el coseno es igual a 1 o el ángulo es 0, los vectores son exactamente similares.



NLP Actual

Algoritmos de Tokenización Avanzada

Byte-Pair Encoding (BPE):

- Empieza con caracteres individuales.
- Combina iterativamente los pares más frecuentes para formar subpalabras.
- Construye el vocabulario de forma **incremental**.
- Maneja palabras desconocidas dividiéndolas en piezas conocidas.
- Usado en GPT-2, GPT-3, RoBERTa

Ejemplo:

"economista" → eco + nom + ista.

WordPiece:

- Similar a BPE, pero selecciona subpalabras según **probabilidad máxima** en el corpus (no solo frecuencia).
- Evita sobresegmentar palabras poco comunes.
- Mejora la cobertura del vocabulario en múltiples idiomas.

Ejemplo:

"economista" → eco + ##nomista

(los ## indican que es continuación de otra subpalabra).



Modelos Transformers para NLP

BERT (Bidirectional Encoder Representations from Transformers)


- Desarrollado por Google (2018)
- Comprensión bidireccional del contexto
- Pre-entrenado en grandes corpus de texto
- Revolucionó el estado del arte en múltiples tareas
- Variantes: RoBERTa, DistilBERT, ALBERT

Que hace?


- **Lee el texto de entrada** y lo convierte en **vectores numéricos** (representaciones internas).
- Captura **significado y contexto** de las palabras en una oración.
- Permite que el modelo “**entienda**” **el texto** aunque no genere nada todavía.
- Sirve como base para tareas como:
 - Clasificar documentos (*¿positivo o negativo?*)
 - Encontrar similitudes (*¿qué tan parecidos son dos textos?*)
 - Buscar información (*¿qué artículos hablan de inflación?*)

El espacio vectorial del lenguaje


- El encoder convierte textos en **vectores en un espacio matemático**.
- **Cercanía = similitud de significado** (ej. “inflación” y “recesión” están más cerca que “inflación” y “gato”).
- Permite a la computadora **comparar, clasificar y buscar textos** basándose en su contenido.
- Base de aplicaciones como:
 - Motores de búsqueda inteligentes.
 - Recomendadores de artículos.
 - Detección de temas en documentos.



Male-Female



Verb Tense



Country-Capital

Ejemplos de espacios vectoriales:

<https://projector.tensorflow.org/>

GPT (Generative Pre-trained Transformer)

- **Desarrollado por OpenAI**, pero hoy existen muchos modelos equivalentes (LLaMA, Mistral, Falcon, etc.).
- **Enfoque autoregresivo**: predice el siguiente token basándose en los anteriores.
- **Excelente en generación de texto**: escritura coherente, resúmenes, diálogos.
- **Entrenado en grandes cantidades de texto** → aprende patrones estadísticos del lenguaje.
- **Capacidades emergentes**: razonamiento, traducción, responder preguntas, programar.
- **Limitaciones**: no tiene “conocimiento propio” ni entiende como un humano → puede inventar respuestas (*alucinaciones*).
- **Aplicaciones económicas**: análisis automático de documentos, generación de reportes, chatbots especializados.