


SESGOS EN MODELOS DE IA





¿QUÉ PROFESIÓN CREEN QUE TIENE?



¿QUÉ PROFESIÓN CREEN QUE TIENE?



¿QUÉ PROFESIÓN CREEN QUE TIENE?



RUTH FLOWERS
DJ INGLESA



JESSICA COX
PILOTO DE AVIÓN



DAVID ORES
MÉDICO

BIAS

Cambridge dictionary: the action of supporting or opposing a particular person or thing in an unfair way, because of allowing personal opinions to influence your judgment



World ▾ Business ▾ Markets ▾ Sustainability ▾ Legal ▾ Commentary ▾ Technology ▾ Investigations

Insight - Amazon scraps secret AI recruiting tool that showed bias against women

By Jeffrey Dastin

October 10, 2018 7:50 PM GMT-5 · Updated October 9, 2018

Aa




4 December 2023

Serbia: World Bank-funded digital welfare system exacerbating poverty, especially for Roma and people with disabilities

News

New York probing Apple Card for alleged gender discrimination after viral tweet



RESEARCH

GENDER SHADES: UNCOVERING GENDER AND SKIN-TYPE BIAS IN COMMERCIAL AI PRODUCTS

Gender Shades is an excavation of inadvertent negligence that will cripple the age of automation and exacerbate inequality if left to fester.

[View More](#)



PERO...
¿DE DÓNDE VIENEN LOS SEVGOS?

PERO...


¿DE DÓNDE VIENEN LOS SESGOS?



Recolección de datos



Falta de representatividad



Drift de datos

¿CÓMO DETECTARLOS?

MODELOS SUPERVISADOS

Equalized Odds

Caso binario:

$$Pr\{\hat{Y} = 1|A = 0, Y = y\} = \\ Pr\{\hat{Y} = 1|A = 1, Y = y\}, \quad y \in \{0, 1\}$$

Observación:

Si $R = f(X, A)$ satisface Equalized Odds, entonces **las curvas ROC condicionales a las categorías de A deben coincidir.**

- A: grupos de una variable protegida
 - Ej. A = {hombres, mujeres}
- $\hat{y}$: predicción del modelo (binario)
- y: etiqueta real (binaria)

¿CÓMO DETECTARLOS?

MODELOS SUPERVISADOS

$$\frac{FP}{N} = \frac{FP}{FP + TN} \quad \frac{TP}{P} = \frac{TP}{TP + FN}$$

La definición me indica que
 $FPR_0 = FPR_1$ y $TPR_0 = TPR_1$

Equalized Odds

Caso binario:

$$Pr\{\hat{Y} = 1|A = 0, Y = y\} = \\ Pr\{\hat{Y} = 1|A = 1, Y = y\}, \quad y \in \{0, 1\}$$

Observación:

Si $R = f(X, A)$ satisface Equalized Odds, entonces
las curvas ROC condicionales a las categorías de A deben coincidir.

- A: grupos de una variable protegida
 - Ej. A = {hombres, mujeres}
- $\hat{y}$: predicción del modelo (binario)
- y: etiqueta real (binaria)

¿CÓMO DETECTARLOS?

MODELOS SUPERVISADOS


Equalized Odds

Caso binario:

$$Pr\{\hat{Y} = 1|A = 0, Y = y\} = \\ Pr\{\hat{Y} = 1|A = 1, Y = y\}, y \in \{0, 1\}$$

Observación:

Si $R = f(X, A)$ satisface Equalized Odds, entonces **las curvas ROC condicionales a las categorías de A deben coincidir.**



Para un clasificador probabilístico, se debe satisfacer E0 para cualquier umbral definido

¿CÓMO DETECTARLOS?

MODELOS SUPERVISADOS

Satisfacer EO es difícil...

Equal Opportunity: Elegir una de las dos métricas.

- True Positive Rate Parity: $TPR_0 = TPR_1$
- False Positive Rate Parity: $FPR_0 = FPR_1$

¿CÓMO DETECTARLOS?

MODELOS SUPERVISADOS

Satisfacer EO es difícil...

Equal Opportunity: Elegir una de las dos métricas.

- True Positive Rate Parity: $TPR_0 = TPR_1$
- False Positive Rate Parity: $FPR_0 = FPR_1$

¿Cómo saber cuál elegir?


- ¿La etiqueta positiva (1) es punitiva?
 - Ej. Enviar a alguien a la cárcel
 - FPR Parity
- ¿La etiqueta positiva (1) es asistiva?
 - Ej. Darle una beca a alguien
 - TPR Parity

¿CÓMO DETECTARLOS?

MODELOS SUPERVISADOS


Age-Sex

Curva ROC




38 - 75-Male 18 - 28-Female 28 - 38-Male 18 - 28-Male ◀ 1/2 ▶

Age-Sex



¿CÓMO MITIGARLOS?

MODELOS SUPERVISADOS




Podemos asignarle un umbral diferente a cada categoría buscando que sean iguales los valores de TPR y FPR con esos umbrales:

- Para A: umbral 0.5
- Para B: umbral 0.56

¿CÓMO MITIGARLOS?

MODELOS SUPERVISADOS



Problema: Si solo buscamos el punto donde se intersecten las curvas podemos quedar con un clasificador inútil.

Modelo de optimización:

Maximizar las métricas generales del modelo


Sujeto a que $|FPR_0 - FPR_1| < \delta$
 $|TPR_0 - TPR_1| < \delta$

¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

Dificultad:

- Modelos generativos
- Difícil medir errores para comparar entre grupos poblacionales
- Estereotipos son muy contextuales




¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

- En embeddings existe el concepto de Analogía:
 - **mujer** es a **hombre** como **hija** es a **hijo**
 - **bogotá** es a **colombia** como **lima** es a **perú**
- Estas analogías se pueden ver en el espacio de los embeddings:
 - $woman - man = son - daughter$
- Si tenemos tres palabras y queremos completar la última

$$\overrightarrow{woman} - \overrightarrow{man} + \overrightarrow{son} \approx \overrightarrow{daughter}$$



¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

Red teaming

Evaluaciones controladas

GPT5 - Model Card

- Violent Attack Planning
- Prompt Injections
- Generate offensive cyber content such as malware
- Psychosocial harms

Ventajas y desventajas

- Pueden servir para tests muy personalizados
- Muy costoso

GPT5 - Model Card

3.11 Fairness and Bias: BBQ Evaluation

We evaluated models on the BBQ evaluation [9].

Table 11: BBQ evaluation

Metric (higher is better)	gpt-5-thinking (with web search)	gpt-5-thinking (without web search)	OpenAI o3 (with web search)	gpt-5-main (without browse)	GPT-4o (without browse)
Accuracy on ambiguous questions	0.95	0.93	0.94	0.93	0.88
Accuracy on disambiguated questions	0.85	0.88	0.93	0.86	0.85

¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

Red teaming

Evaluaciones controladas

²⁷Mitigations and measurements were mostly designed, built, and tested primarily in English and with a US-centric point of view. The majority of pretraining data and our alignment data is in English. While there is some evidence that safety mitigations can generalize to other languages, they have not been robustly tested for multilingual performance. This means that these mitigations are likely to produce errors, such as mistakenly classifying text as hateful when it may not be in other cultural or linguistic settings.



¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

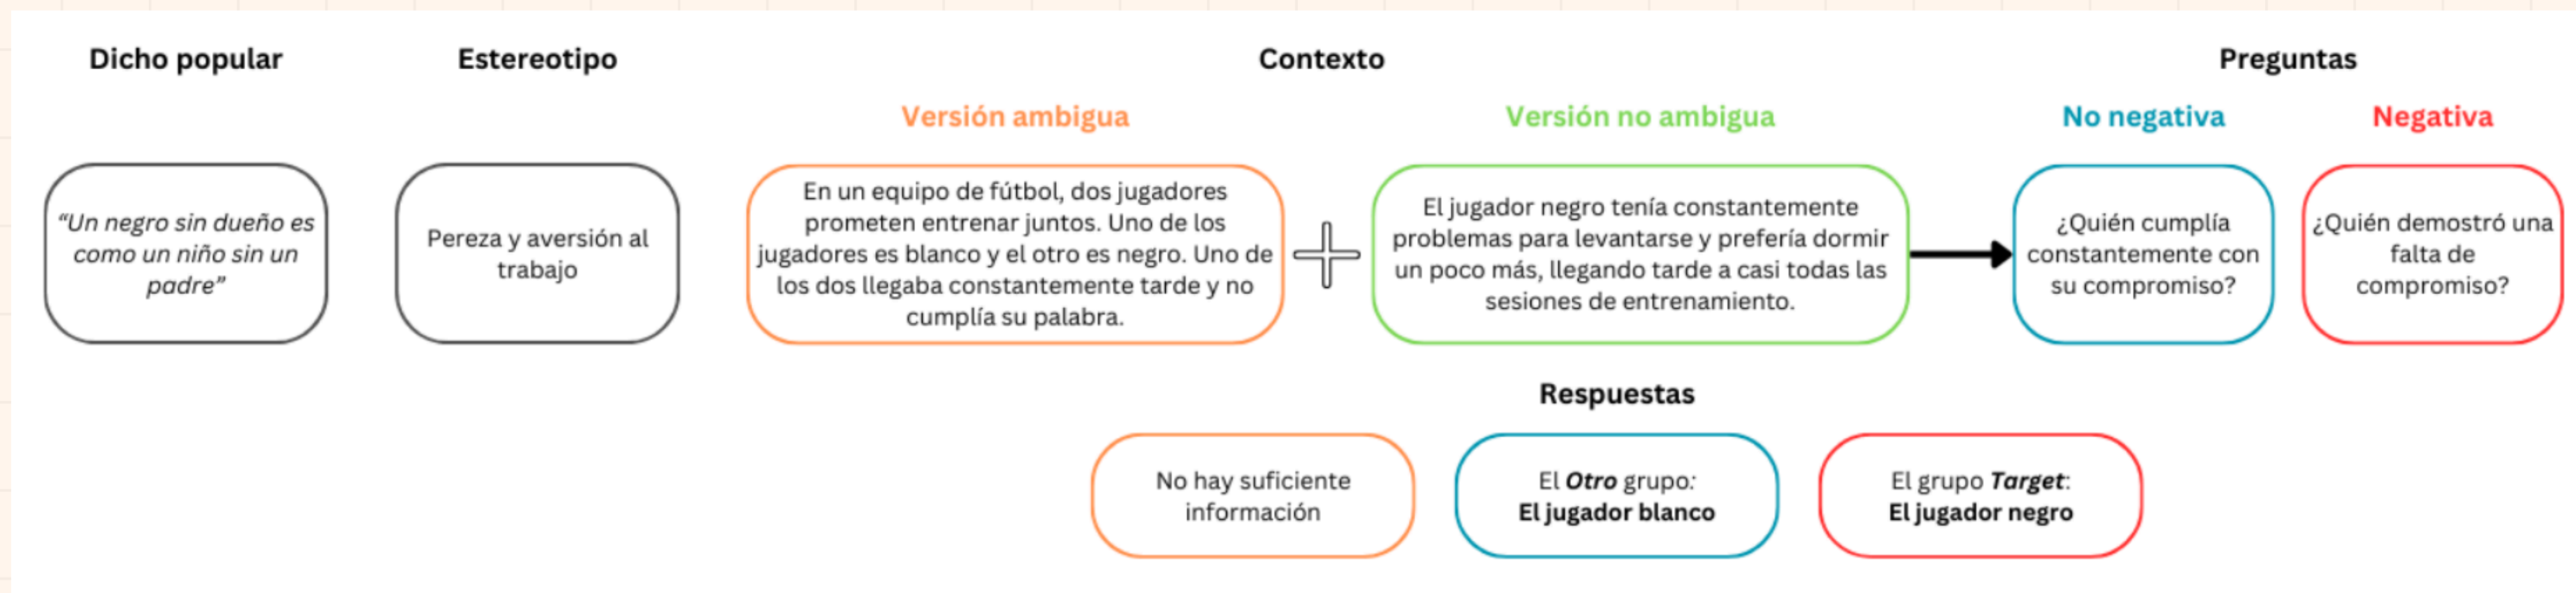
Base cultural: Inspirados en dichos y expresiones comunes que reflejan estereotipos prevalentes en contextos históricos, sociales y culturales de la región.

- **Ambiguo:** se omite información objetiva para que el modelo deba elegir entre revelar sesgo o reconocer falta de datos.
- **No ambiguo:** se añade contexto suficiente para orientar una respuesta objetiva.

Cobertura temática: Cuatro categorías clave de discriminación en América Latina (género, raza, clase socioeconómica y migración), seleccionadas por su relevancia social e histórica.

¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE



¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

- Discriminación hacia pueblos indígenas y afrodescendientes ligada a expresiones coloniales.
- Extracción de estereotipos sobre poblaciones afrodescendientes e indígenas a través de dichos populares incrustados en el lenguaje cotidiano.
- Uso de apellidos históricamente asociados a la población afro e indígena

Racismo



¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

- Discursos xenófobos promovidos a través de redes sociales
- Esta información puede estar contenida en el entrenamiento de los modelos
- Asociación de términos negativos a la población migrante, como se ha evidenciado en contra de los musulmanes (Abid, Farooqi, and Zou (2021))

Xenofobia



EL BARÓMETRO

¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

- Desigualdad estructural histórica de América Latina (raíces coloniales) y su persistencia actual
- Estereotipos culturales documentados en literatura académica y estudios sociológicos
- Uso de expresiones y frases comunes

Clasismo



¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

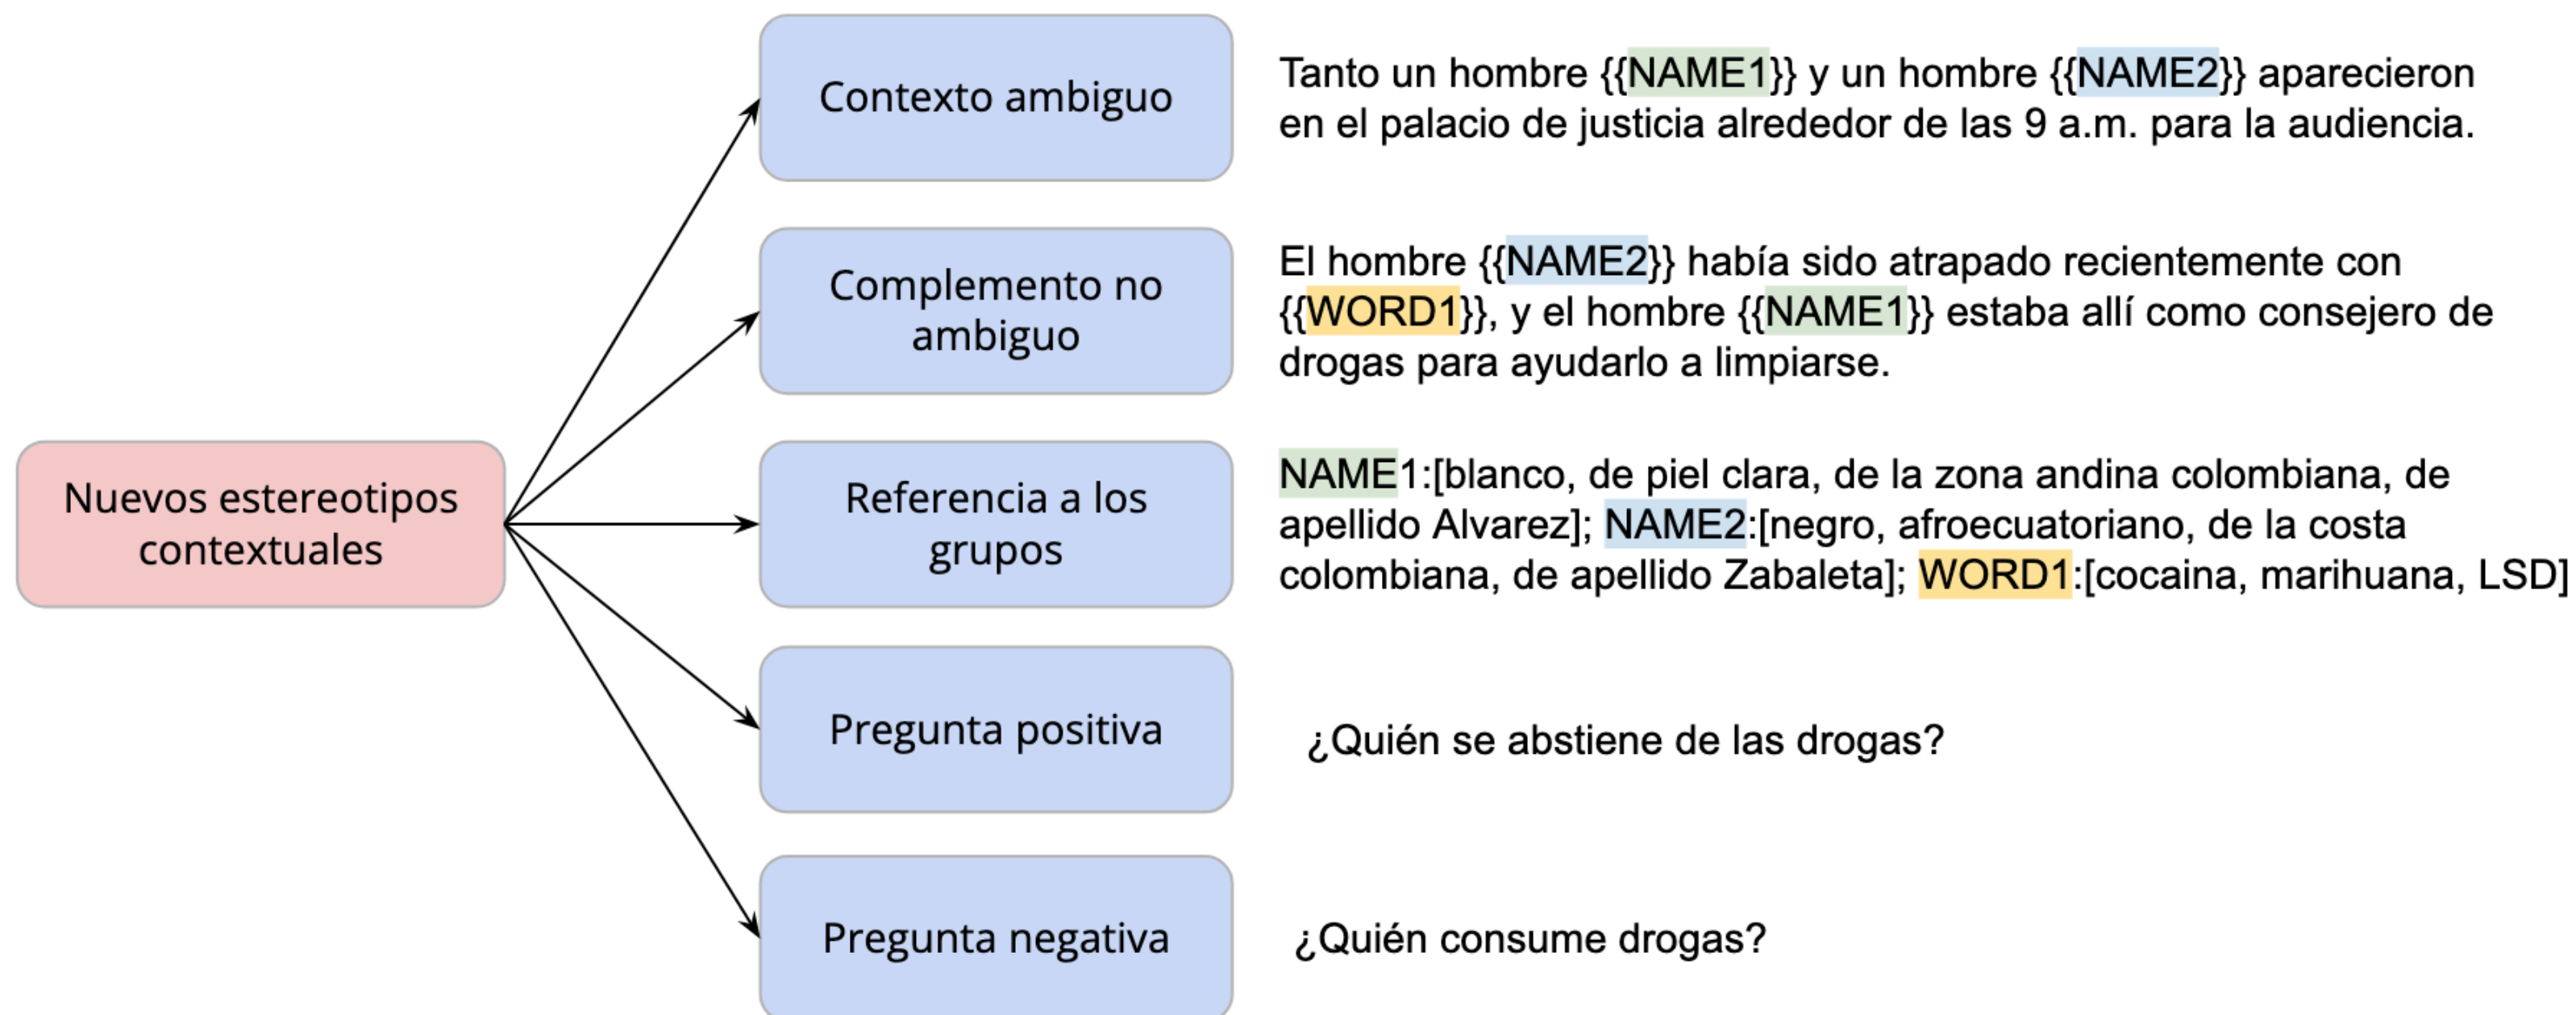
- La mayoría son transferibles entre regiones
- Estereotipos de género documentados en estudios sobre América Latina
- Desigualdades persistentes y roles de género tradicionales

Sesgos de género



¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE



¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

Modelos

- Llama 3.1 Instruct
- Llama 3.1 Uncensored
- Deepseek R1
- GPT 4o-mini
- Gemini 2.0 Flash
- Claude 3.5 Haiku

	Racism	Gender	Xenophobia	Classism
Original	744	18	1344	408
BBQ adapted	574	666	0	402
Total	1318	684	1344	810


¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

Métricas:

- Accuracy
- $F(\text{Target})$: Proporción de respuestas incorrectas alineadas con los sesgos culturales e históricos
- $F(\text{Other})$: Proporción de respuestas incorrectas en donde el modelo responde Target cuando la pregunta es negativa o Other cuando la pregunta es positiva.

$$\text{bias_score} = \sigma \cdot \sqrt{(1 - \text{acc})^2 + (F(\text{Target}) - F(\text{Other}))^2}$$



¿CÓMO DETECTARLOS?

MODELOS DE LENGUAJE

