

Procesamiento de Imágenes

HE2: IA Aplicada

¿Qué es una imagen?




Qué características identifican?

Cuál es la unidad mínima de una imagen?

Cómo se define el tamaño?

¿Qué es una imagen?



141 1 píxel

Tiene 1 canal:
0 => negro
255 => blanco

¿Qué es una imagen (a color)?



Gray scale

123



R G B
??? ??? ???

(225, 76, 43)

Actividad: Encuentren el color más cercano!

<https://photocolorpicker.com/rgb-color-picker>

¿Cómo crear una arquitectura MLP con imágenes?


Quiero clasificar si una imagen es un perro o no. Cómo lo puedo hacer?

1. Función de pérdida? Binary Cross Entropy
2. Capa de salida? 1 neurona con función de activación sigmoide
3. X? Los pixeles ?



Imagen de 256 x 256

Actividad: Cuantas características son?




¿Problemas de usar MLP con imágenes?

1. Escalabilidad: El número de parámetros explota.
2. Estructura espacial: Al compactar todo en un vector, se pierden las relaciones entre píxeles vecinos.



Imagen de 256 x 256




Procesamiento de imágenes: Filtros/Kernels



??



BLUR:
Filtro
Promedio



¡Modo retrato de celulares!

Operación de convolución

Source layer

5	2	6	8	2	0	1	2
4	3	4	5	1	9	6	3
3	9	2	4	7	7	6	9
1	3	4	6	8	2	2	1
8	4	6	2	3	1	8	8
5	8	9	0	1	0	2	3
9	2	6	6	3	6	2	1
9	8	8	2	6	3	4	5

Convolutional
kernel

-1	0	1
2	1	2
1	-2	0

Calculen el valor del pixel siguiente (4)?

Luego de que acabemos la fila, cual es el siguiente valor?

Destination layer

	5						


$$\begin{aligned} &(-1 \times 5) + (0 \times 2) + (1 \times 6) + \\ &(2 \times 4) + (1 \times 3) + (2 \times 4) + \\ &(1 \times 3) + (-2 \times 9) + (0 \times 2) = 5 \end{aligned}$$

Ejemplo: Filtro/Kernel promedio



Promediar todos los valores vecinos en un kernel

$$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$




Cómo se vería el kernel (i.e., la matriz) para un tamaño de 3x3?
Qué ocurre si el tamaño del kernel aumenta? 5x5, 10x10, 25x25...

Otros filtros



Imagen original

$$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$



Kernel promedio

$$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$



Sobel X

$$\begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$



Sobel Y

$$\begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

Propiedades importantes de la convolución: Padding

Source layer

5	2	6	8	2	0	1	2
4	3	4	5	1	9	6	3
3	9	2	4	7	7	6	9
1	3	4	6	8	2	2	1
8	4	6	2	3	1	8	8
5	8	9	0	1	0	2	3
9	2	6	6	3	6	2	1
9	8	8	2	6	3	4	5

Convolutional
kernel

-1	0	1
2	1	2
1	-2	0

Destination layer

	5						

$$\begin{aligned} &(-1 \times 5) + (0 \times 2) + (1 \times 6) + \\ &(2 \times 4) + (1 \times 3) + (2 \times 4) + \\ &(1 \times 3) + (-2 \times 9) + (0 \times 2) = 5 \end{aligned}$$

Propiedades importantes de la convolución:

Padding

17	10	15	16	17				
16	9	8	9	10				
3	2	1	2	3	4	5	6	7
10	9	8	9	10	11	12	13	14
17	16	15	16	17	18	19	20	21
		22	23	24	25	26	27	28



Original image



Added pixels




Kernel 5x5


Si no tuviera padding,
desde qué píxel
comienza?

Propiedades importantes de la convolución: Stride


Convolution
with Stride=1




Output



Convolution
with Stride=2




Output



Convolutional Neural Networks



||



3x512x512


Kernel 3x3x3




+

=


Mapa de características
512x512
(dependiendo si tiene padding, stride..)




Convolutional Neural Networks



Convolutional Neural Networks: Pooling



Convolutional Neural Networks




Convolutional Neural Networks: Arquitecturas

Esto se usa mucho para extraer características, pero lo que vimos de capas densas (MLP, fully connected layers, etc) se sigue utilizando!!


1. Se extraen características con capas convolucionales
2. Se usan los módulos que ya vimos para predecir/clasificar!

Convolutional Neural Networks: Arquitecturas

The Architecture of Convolutional Neural Networks



Convolutional Neural Networks: Arquitecturas



Aplicaciones en Economía

Using Neural Networks to Predict Microspatial Economic Growth[†]

By ARMAN KHACHIYAN, ANTHONY THOMAS, HUYE ZHOU, GORDON HANSON,
ALEX CLONINGER, TAJANA ROSING, AND AMIT K. KHANDLWAL*

We apply deep learning to daytime satellite imagery to predict changes in income and population at high spatial resolution in US data. For grid cells with lateral dimensions of 1.2 km and 2.4 km (where the average US county has dimension of 51.9 km), our model predictions achieve R^2 values of 0.85 to 0.91 in levels, which far exceed the accuracy of existing models, and 0.32 to 0.46 in decadal changes, which have no counterpart in the literature and are 3–4 times larger than for commonly used nighttime lights. Our network has wide application for analyzing localized shocks. (JEL C45, R11, R23)

[Using Neural Network to Predict Microspatial Economic Growth](#)

Hay demasiadas aplicaciones. Preguntenle a ChatGPT “Aplicaciones de CNN en Economía con referencias”!

CNNPred: CNN-based stock market prediction using several data sources

Ehsan Hoseinzade^a, Saman Haratizadeh^a

^aFaculty of New Sciences and Technologies, University of Tehran, North Kargar Street,
1439957131 Tehran, Iran

Abstract

Feature extraction from financial data is one of the most important problems in market prediction domain for which many approaches have been suggested. Among other modern tools, convolutional neural networks (CNN) have recently been applied for automatic feature selection and market prediction. However, in experiments reported so far, less attention has been paid to the correlation among different markets as a possible source of information for extracting features. In this paper, we suggest a CNN-based framework with specially designed CNNs, that can be applied on a collection of data from a variety of sources, including different markets, in order to extract features for predicting the future of those markets. The suggested framework has been applied for predicting the next days direction of movement for the indices of S&P 500, NASDAQ, DJI, NYSE, and RUSSELL markets based on various sets of initial features. The evaluations show a significant improvement in predictions performance compared to the state of the art baseline algorithms.

[CNNPred Arxiv](#)

¡Caso de Estudio Real! Detección Automática de Períodos de Estabilización en Pozos Petroleros

Contexto. Ecopetrol necesita identificar períodos donde la producción de crudo se mantiene estable para realizar pronósticos confiables. Actualmente, un ingeniero experto analiza manualmente el histórico de cada pozo, proceso que resulta costoso y lento al escalar a cientos de pozos.

Datos Disponibles

- **Series temporales por pozo:** producción diaria de crudo, inyección de agua, presión, temperatura, etc.
- **Etiquetas del experto:** períodos marcados como "estables" vs "no estables"
- **Histórico:** múltiples años de datos para cientos de pozos

Objetivo del Modelo. Desarrollar un modelo de Deep Learning que replique el criterio del ingeniero experto para:

- Detectar automáticamente períodos de estabilización
- Reducir tiempo de análisis de semanas a minutos

Desafío Técnico ¿Cómo capturar el conocimiento implícito del experto que considera patrones complejos, contexto histórico y relaciones entre variables que no siguen reglas simples?

Impacto Esperado

- **Eficiencia:** Análisis instantáneo vs semanas de trabajo manual
- **Escalabilidad:** Procesar todos los pozos simultáneamente
- **Consistencia:** Criterios uniformes en toda la operación