


Transformers




"Attention Is All You Need"^[1] is a 2017 landmark^{[2][3]} research paper in machine learning authored by eight scientists working at Google. The paper introduced a new deep learning architecture known as the transformer, based on the attention mechanism proposed in 2014 by Bahdanau et al.^[4] It is considered a foundational^[5] paper in modern artificial intelligence, and a main contributor to the AI boom, as the transformer approach has become the main architecture of a wide variety of AI, such as large language models.^{[6][7]} At the time, the focus of the research was on improving Seq2seq techniques for machine translation, but the authors go further in the paper, foreseeing the technique's potential for other tasks like question answering and what is now known as multimodal generative AI.^[1]

As of 2025, the paper has been cited more than 173,000 times,^[10] placing it among the top ten most-cited papers of the 21st century.^[11]



¿Cómo funciona Chat GPT?



“La cafetería del campus se negó a venderme un café con leche porque solo sirve bebidas veganas. Al final, me dieron agua tibia. Su servicio era tan bueno como sus precios y calidad.”

Objetivo: Diseñar una red que procese este texto para

- Clasificar la reseña como positiva o negativa
- Responder preguntas como: “¿La cafetería vende productos lácteos?”

Suponga que cada palabra la podemos representar por un vector de 1024 dimensiones.

¿De qué tamaño sería el input en una red neuronal MLP?

33.792 “características”

“La cafetería del campus se negó a venderme un café con leche porque solo sirve bebidas veganas. Al final, me dieron agua tibia. Su servicio era tan bueno como sus precios y calidad.”

Objetivo: Diseñar una red que procese este texto para

- Clasificar la reseña como positiva o negativa
- Responder preguntas como: “¿La cafetería vende productos lácteos?”

Problemas:

1. El input codificado puede ser demasiado grande
2. Cada input es de distinto tamaño
3. El lenguaje es ambiguo. ¿“**Su**” a qué se refiere?

“ La **cafetería** del campus se negó a venderme un café con leche porque solo sirve bebidas veganas. Al final, me dieron agua tibia. **Su** servicio era tan bueno como sus precios y calidad.”

Objetivo: Diseñar una red que procese este texto para


- Clasificar la reseña como positiva o negativa
- Responder preguntas como: “¿La cafetería vende productos lácteos?”

Problemas:

1. El input codificado puede ser demasiado grande
2. Cada input es de distinto tamaño
3. El lenguaje es ambiguo. ¿“**Su**” a qué se refiere? **¡ATENCIÓN!**

Back to the Basics: MLP

$$\mathbf{f}[\mathbf{x}] = \mathbf{ReLU}(\beta + \Omega \mathbf{x})$$



Self-Attention Block

El corazón de los transformers


Un bloque de self-attention $\text{sa}[\bullet]$ toma N inputs $x_1, x_2, \dots, x_N$ cada uno de dimensión $D \times 1$ y retorna N outputs, de los cuales cada uno es también de tamaño $D \times 1$. En NLP, cada input representa una **palabra***.

1. Un conjunto de valores se computan para cada input m

$$\mathbf{v}_m = \beta_v + \Omega_v \mathbf{x}_m$$

donde $\beta_v \in \mathbb{R}^{D \times 1}$ y $\Omega_v \in \mathbb{R}^{D \times D}$

Actividad 1: Dibuje la red neuronal subyacente si $D=2$





Self-Attention Block

El corazón de los transformers

Ejemplo: “Hola soy Daniel” $\implies \mathbf{x}_{\text{Hola}} = [1.5, 3], \mathbf{x}_{\text{soy}} = [1, 2], \mathbf{x}_{\text{Daniel}} = [4, 5]$

$$\mathbf{v}_{\text{Hola}} = [0.5, 0.1]$$




Self-Attention Block

El corazón de los transformers

Ejemplo: “Hola soy Daniel” $\implies \mathbf{x}_{\text{Hola}} = [1.5, 3], \mathbf{x}_{\text{soy}} = [1, 2], \mathbf{x}_{\text{Daniel}} = [4, 5]$

$$\mathbf{v}_{\text{Hola}} = [0.5, 0.1] \quad \mathbf{v}_{\text{soy}} = [0.7, 0.2]$$





Self-Attention Block

El corazón de los transformers

Ejemplo: “Hola soy Daniel” $\implies \mathbf{x}_{\text{Hola}} = [1.5, 3], \mathbf{x}_{\text{soy}} = [1, 2], \mathbf{x}_{\text{Daniel}} = [4, 5]$

$$\mathbf{v}_{\text{Hola}} = [0.5, 0.1] \quad \mathbf{v}_{\text{soy}} = [0.7, 0.2] \quad \mathbf{v}_{\text{Daniel}} = [0.3, 0.5]$$



Self-Attention Block

El corazón de los transformers

2. El output m-ésimo $\mathbf{sa}_m[\mathbf{x}_1, \dots, \mathbf{x}_N]$ es una suma ponderada de todos los valores $\mathbf{v}_1, \dots, \mathbf{v}_N$:

$$\mathbf{sa}_m[\mathbf{x}_1, \dots, \mathbf{x}_N] = \sum_{i=1}^N a[\mathbf{x}_i, \mathbf{x}_m] \mathbf{v}_i$$

Self-Attention Block

El corazón de los transformers

Ejemplo: “Hola soy Daniel” $\implies \mathbf{x}_{\text{Hola}} = [1.5, 3], \mathbf{x}_{\text{soy}} = [1, 2], \mathbf{x}_{\text{Daniel}} = [4, 5]$

$$\mathbf{v}_{\text{Hola}} = [0.5, 0.1] \quad \mathbf{v}_{\text{soy}} = [0.7, 0.2] \quad \mathbf{v}_{\text{Daniel}} = [0.3, 0.5]$$

$$\text{sa}_{\text{Hola}}[\mathbf{x}_{\bullet}] = \boxed{} \mathbf{v}_{\text{Hola}} + \boxed{} \mathbf{v}_{\text{soy}} + \boxed{} \mathbf{v}_{\text{Daniel}}$$

Actividad 2: Complete el self-attention de Hola

Self-Attention Block

El corazón de los transformers

Ejemplo: “Hola soy Daniel” $\implies \mathbf{x}_{\text{Hola}} = [1.5, 3], \mathbf{x}_{\text{soy}} = [1, 2], \mathbf{x}_{\text{Daniel}} = [4, 5]$
 $\mathbf{v}_{\text{Hola}} = [0.5, 0.1] \mathbf{v}_{\text{soy}} = [0.7, 0.2] \mathbf{v}_{\text{Daniel}} = [0.3, 0.5]$

$$\text{sa}_{\text{Hola}}[\mathbf{x}_{\bullet}] = a[\mathbf{x}_{\text{Hola}}, \mathbf{x}_{\text{Hola}}] \mathbf{v}_{\text{Hola}} + a[\mathbf{x}_{\text{soy}}, \mathbf{x}_{\text{Hola}}] \mathbf{v}_{\text{soy}} + a[\mathbf{x}_{\text{Daniel}}, \mathbf{x}_{\text{Hola}}] \mathbf{v}_{\text{Daniel}}$$

Actividad 3: Cree los self-attention para el resto de inputs

Self-Attention Block

El corazón de los transformers

2. El output m -ésimo $\mathbf{sa}_m[\mathbf{x}_1, \dots, \mathbf{x}_N]$ es una suma ponderada de todos los valores $\mathbf{v}_1, \dots, \mathbf{v}_N$:

$$\mathbf{sa}_m[\mathbf{x}_1, \dots, \mathbf{x}_N] = \sum_{i=1}^N a[\mathbf{x}_i, \mathbf{x}_m] \mathbf{v}_i$$




Para calcular la atención $a[\mathbf{x}_i, \mathbf{x}_m]$ es necesario aplicar otras dos transformaciones lineales a los inputs:

$$\begin{aligned} \mathbf{q}_m &= \beta_q + \Omega_q \mathbf{x}_m \\ \mathbf{k}_i &= \beta_k + \Omega_k \mathbf{x}_i \end{aligned} \quad \Longrightarrow \quad \begin{aligned} a[\mathbf{x}_i, \mathbf{x}_m] &= \text{softmax}_i[\mathbf{k}_i^T \mathbf{q}_m] \\ &= \frac{\exp[\mathbf{k}_i^T \mathbf{q}_m]}{\sum_{j=1}^N \exp[\mathbf{k}_j^T \mathbf{q}_m]} \end{aligned}$$

Self-Attention Block

El corazón de los transformers

Ejemplo: “Hola soy Daniel” $\implies \mathbf{x}_{\text{Hola}} = [1.5, 3], \mathbf{x}_{\text{soy}} = [1, 2], \mathbf{x}_{\text{Daniel}} = [4, 5]$



Self-Attention Block

El corazón de los transformers

Ejemplo: “Hola soy Daniel” $\implies \mathbf{x}_{\text{Hola}} = [1.5, 3], \mathbf{x}_{\text{soy}} = [1, 2], \mathbf{x}_{\text{Daniel}} = [4, 5]$

$$\mathbf{v}_{\text{Hola}} = [0.5, 0.1] \quad \mathbf{v}_{\text{soy}} = [0.7, 0.2] \quad \mathbf{v}_{\text{Daniel}} = [0.3, 0.5]$$

$$\mathbf{q}_{\text{Hola}} = [3, 1] \quad \mathbf{q}_{\text{soy}} = [2, 5] \quad \mathbf{q}_{\text{Daniel}} = [0, 2]$$

$$\mathbf{k}_{\text{Hola}} = [1, 2] \quad \mathbf{k}_{\text{soy}} = [1, 0] \quad \mathbf{k}_{\text{Daniel}} = [0, 1]$$

$$\mathbf{sa}_{\text{Hola}}[\mathbf{x}_{\bullet}] = a[\mathbf{x}_{\text{Hola}}, \mathbf{x}_{\text{Hola}}] \mathbf{v}_{\text{Hola}} + a[\mathbf{x}_{\text{soy}}, \mathbf{x}_{\text{Hola}}] \mathbf{v}_{\text{soy}} + a[\mathbf{x}_{\text{Daniel}}, \mathbf{x}_{\text{Hola}}] \mathbf{v}_{\text{Daniel}}$$

Actividad 4: Calcule los coeficientes de atención sin aplicar la **softmax**,
i.e., $a[\mathbf{x}_i, \mathbf{x}_m] = \mathbf{k}_i^T \cdot \mathbf{q}_m$

Actividad 5: Calcule los coeficientes de atención sin aplicar la **softmax**,
para el resto de self-attention (Use la actividad 3)

Self-Attention Block

El corazón de los transformers

Ejemplo: “Hola soy Daniel” $\implies \mathbf{x}_{\text{Hola}} = [1.5, 3], \mathbf{x}_{\text{soy}} = [1, 2], \mathbf{x}_{\text{Daniel}} = [4, 5]$

$$\mathbf{v}_{\text{Hola}} = [0.5, 0.1] \quad \mathbf{v}_{\text{soy}} = [0.7, 0.2] \quad \mathbf{v}_{\text{Daniel}} = [0.3, 0.5]$$

$$\mathbf{q}_{\text{Hola}} = [3, 1] \quad \mathbf{q}_{\text{soy}} = [2, 5] \quad \mathbf{q}_{\text{Daniel}} = [0, 2]$$

$$\mathbf{k}_{\text{Hola}} = [1, 2] \quad \mathbf{k}_{\text{soy}} = [1, 0] \quad \mathbf{k}_{\text{Daniel}} = [0, 1]$$

$$\mathbf{sa}_{\text{Hola}}[\mathbf{x}_{\bullet}] = a[\mathbf{x}_{\text{Hola}}, \mathbf{x}_{\text{Hola}}] \mathbf{v}_{\text{Hola}} + a[\mathbf{x}_{\text{soy}}, \mathbf{x}_{\text{Hola}}] \mathbf{v}_{\text{soy}} + a[\mathbf{x}_{\text{Daniel}}, \mathbf{x}_{\text{Hola}}] \mathbf{v}_{\text{Daniel}}$$

Sin softmax: $\mathbf{sa}_{\text{Hola}}[\mathbf{x}_{\bullet}] = 5 \cdot \mathbf{v}_{\text{Hola}} + 3 \cdot \mathbf{v}_{\text{soy}} + 1 \cdot \mathbf{v}_{\text{Daniel}}$

Con softmax: $\mathbf{sa}_{\text{Hola}}[\mathbf{x}_{\bullet}] = 0.86 \cdot \mathbf{v}_{\text{Hola}} + 0.11 \cdot \mathbf{v}_{\text{soy}} + 0.03 \cdot \mathbf{v}_{\text{Daniel}}$

Self-Attention Block

El corazón de los transformers

Notación Matricial

Si los N inputs $\mathbf{x}_1, \dots, \mathbf{x}_N$ forman las columnas de la matriz $\mathbf{X} \in \mathbb{R}^{D \times N}$. Los “valores”, “queries” y “keys” se pueden calcular de la siguiente forma:

$$\mathbf{V}[\mathbf{X}] = \beta_v \mathbf{1}^T + \Omega_v \mathbf{X}$$

$$\mathbf{Q}[\mathbf{X}] = \beta_q \mathbf{1}^T + \Omega_q \mathbf{X}$$

$$\mathbf{K}[\mathbf{X}] = \beta_k \mathbf{1}^T + \Omega_k \mathbf{X}$$

Donde $\mathbf{1}$ es un vector de dimensiones $N \times 1$ lleno de unos. El **self-attention** se calcula entonces como:

$$\mathbf{Sa}[\mathbf{X}] = \mathbf{V}[\mathbf{X}] \cdot \text{Softmax} [\mathbf{K}[\mathbf{X}]^T \mathbf{Q}[\mathbf{X}]]$$

Self-Attention Block


El corazón de los transformers

Notación Matricial

¿Cuales son los parámetros del modelo?

$$\phi = \{\beta_q, \Omega_q, \beta_k, \Omega_k, \beta_v, \Omega_v\}$$

Actividad 7: Los vectores de los inputs tienen dimensión $D=256$. Cuantos pesos tendrá este mecanismo?



Self-Attention Block


El corazón de los transformers

Múltiples cabezas

Múltiples mecanismos self-attention se ejecutan en paralelo, y se conoce como **multi-head self-attention**. H conjuntos distintos de valores se computan, como se observa en la figura.


Actividad 8: Los vectores de los inputs tienen dimensión $D=1024$.

Si uso 4 cabezas, **cuales** son los parámetros y **cuantos** pesos hay?



Prince, S. J. D. (2023). Understanding Deep Learning. MIT Press.

Transformer Layer



En la práctica, así como usamos muchas capas fully connected para clasificar si el ingreso es menor o mayor a 50mil dolares (Parcial 2), o usamos múltiples capas convolucionales, también usamos múltiples capas de Transformers!

Transformers en NLP

<https://platform.openai.com/tokenizer>

1. Tokenización

“Hola soy Daniel”

tokens = [“Hola”, “soy”, “Daniel”]

token IDs = [49864, 28957, 19041]

Actividad 9: Use el tokenizer de ChatGPT para encontrar la división de tokens que hace a la frase “Hola soy Daniel”, qué ocurre si usamos “daniel” en minúscula?

Actividad 10: Abra ChatGPT. Pregúntele cuál es el tamaño del vocabulario. Revise en el tokenizer cuales son los token IDs de los tokens? Que significan los token IDs? Cual es su funcionalidad?

Transformers en NLP

<https://platform.openai.com/tokenizer>

tokens = ["Hola", "soy", "Daniel"]

token IDs = [49864, 28957, 19041]

2. Embeddings

Cada token se mapea a un embedding único de palabra.

2.1 Se hace One Hot Encoding de los N tokens para obtener una matriz $\mathbf{T} \in \mathbb{R}^{|V| \times N}$

$$\mathbf{T} = \begin{array}{ccc} \text{Hola} & \text{soy} & \text{Daniel} \\ 0 & 0 & \vdots \\ 0 & \vdots & 1 \\ \vdots & 1 & \vdots \\ \vdots & \vdots & \vdots \\ 1 & \vdots & 0 \\ \vdots & 0 & 0 \\ 0 & 0 & 0 \end{array}$$

Transformers en NLP

<https://platform.openai.com/tokenizer>


tokens = ["Hola", "soy", "Daniel"]

token IDs = [49864, 28957, 19041]

2. Embeddings

Cada token se mapea a un embedding único de palabra.

2.2 Se utiliza una matriz de embeddings de todo el vocabulario $\Omega_e^{D \times |V|}$



Actividad 10: Pregunten a ChatGPT, cual es la cantidad de dimensiones que se suele usar?

Calcule para $D=1024$ y con el vocabulario de ChatGPT

Transformers en NLP

<https://platform.openai.com/tokenizer>

tokens = ["Hola", "soy", "Daniel"]

token IDs = [49864, 28957, 19041]


2. Embeddings

Cada token se mapea a un embedding único de palabra.

2.2 Se utiliza una matriz de embeddings de todo el vocabulario $\Omega_e^{D \times |V|}$

Ejemplo

Usando $D=2$



Transformers en NLP

<https://platform.openai.com/tokenizer>

tokens = ["Hola", "soy", "Daniel"]

token IDs = [49864, 28957, 19041]


2. Embeddings

Cada token se mapea a un embedding único de palabra.


2.3 Se obtienen los embeddings del input: $\mathbf{X} = \Omega_e \mathbf{T}$

Ejemplo

Usando $D=2$




Modelo de Transformers




Tipos de modelos transformer


Transformer



GPT*



BERT*



*Illustrative example, exact model architecture may vary slightly

