

Fine-tuning y RAGs

Como hacer que los **LLMs** trabajen con sus datos?

Actividad:

Pregúntenle a **ChatGPT** :

¿Quien es el profesor y el profesor complementario de *HE2: Inteligencia Artificial Aplicada a la Economía*?

Como lograrían que ChatGPT les responda de forma correcta/actualizada?

- Teniendo un ChatGPT-Uniandes que esté re-entrenado con toda la información recurrente de la Universidad de los Andes.
- Darle directamente el contexto a ChatGPT.

El problema

Los LLMs son increíbles, pero

1. No conocen los datos específicos de su empresa, negocio, o tema de interés
2. Conocimiento desactualizado
3. Pueden alucinar

SOLUCIÓN: Fine-tuning o RAG

Fine-tuning

Es una técnica que consiste en tomar un modelo pre-entrenado y adaptarlo para una tarea específica.

Hay distintas formas:

1. **Full Fine-tuning:** Se actualizan todos los parámetros del modelo.
2. **Parameter-Efficient Fine-Tuning:** Técnicas que ajustan sólo una pequeña parte del modelo. La más usada: **LoRA (Low-Rank Adaptation)**

Ejemplos: Chatbots de atención al cliente (e.g., Rappi, Uber) que tengan contexto específico (e.g., políticas de devolución, productos específicos, etc.)

Actividades

Fine-tuning

Chatbots de Atención al Cliente (E-commerce)

Objetivo: Entrenar un modelo para responder preguntas sobre políticas de devolución, envíos y productos específicos.

- Qué clase de datos necesitan? Generen un dataset de 5 ejemplos.
- Qué formato usarían?
- Qué modelo base usarían?

Actividades

Fine-tuning

Extracción de Información de Facturas

Objetivo: Extraer campos estructurados de facturas en formato PDF/Imagen.

- Qué clase de datos necesitan? Generen un dataset de 5 ejemplos.
- Qué formato usarían?
- Qué modelo base usarían?

Actividades

Fine-tuning

Clasificador de Sentimientos para Reseñas de Restaurantes

Objetivo: Clasificar reseñas en positivas, negativas o neutras.

- Qué clase de datos necesitan? Generen un dataset de 5 ejemplos.
- Qué formato usarían?
- Qué modelo base usarían?

RAGs

Combina dos componentes:

1. **Retrieval (Recuperación):** Busca información relevante en una base de datos.
2. **Generation (Generación):** Usa esa información para generar una respuesta. Es como darle al modelo un “libro abierto durante el examen”

Cuales tipos de modelos interactúan aquí? Encoder/Decoder?


Como funciona RAG

Paso 0. Cada documento, con un encoder, lo transformamos en vector y lo guardamos en una base de datos vectorial.

Doc 1: "El gato duerme en el sofá"

Doc 2: "El perro corre en el parque"

Doc 3: "El felino descansa en el mueble"




Doc 1 → [0.8, 0.2, 0.1, 0.9, ...]


Doc 2 → [0.1, 0.7, 0.9, 0.2, ...]

Doc 3 → [0.7, 0.3, 0.1, 0.8, ...]

Back to Transformers (lo que vimos)




Modelos Encoder de texto a vector



Como funciona RAG

Paso 0. Cada documento, con un encoder, lo transformamos en vector y lo guardamos en una base de datos vectorial.

Doc 1: "El gato duerme en el sofá"
Doc 2: "El perro corre en el parque"
Doc 3: "El felino descansa en el mueble"



Doc 1 → [0.8, 0.2, 0.1, 0.9, ...]
Doc 2 → [0.1, 0.7, 0.9, 0.2, ...]
Doc 3 → [0.7, 0.3, 0.1, 0.8, ...]



PINECONE / CHROMA / WEAVIATE		
ID	Vector	Metadata
doc1	[0.8, 0.2, ...]	{page: 1}
doc2	[0.1, 0.7, ...]	{page: 2}
doc3	[0.7, 0.3, ...]	{page: 3}

Como funciona RAG

Usuario pregunta algo



1. Convertir pregunta a vector
(**embedding**)



2. Buscar documentos similares en
base de datos vectorial



3. Recuperar los **top K** fragmentos
más relevantes



4. Enviar al **LLM**: [contexto
recuperado + pregunta original]



5. LLM genera respuesta basada en
ese contexto

Actividad

RAG

Monitor de HE2: Inteligencia Artificial Aplicada

Objetivo: Crear un monitor de IA que ayude a estudiantes con temas del curso usando Retrieval-Augmented Generation (RAG).

Primero, escoja los documentos relevantes para este monitor (por lo menos 4 documentos). Segundo, haga un flujo con un ejemplo de las operaciones que debe hacer para la siguiente consulta:

“¿Cómo entiendo mejor Transformers?”

Actividad

RAG

Monitor de HE2: Inteligencia Artificial Aplicada

Objetivo: Crear un monitor de IA que ayude a estudiantes con temas del curso usando Retrieval-Augmented Generation (RAG).

¡Oops! Al realizar el paso cero (transformar cada documento a vector) se encontró un error gravísimo. Los documentos que escogieron son demasiado grandes para los modelos actuales.

- ¿Qué modelos utilizarían (**open source**)? ¿Qué base de datos vectorial usarían?
- ¿Cómo se resuelve el problema de documentos demasiado grandes?
- Cuanta capacidad (palabras aprox.) tienen los modelos que escogieron?